



1. Catene di Esecuzione

Dal Task #3872, runWithFallback usa cascade Ollama-first universale. Se Ollama è offline o lento, la chain scende automaticamente al provider cloud successivo.

Catena Universale — Ollama-first (Task #3872) (server/ai/moderation/provider.ts)



Catena Route AI — pianificazione percorso (server/ai/route-provider-config.ts) [configurabile: DB ai_route_provider_chain / env ROUTE_AI_PROVIDERS]



Cascade universale (Task #3872): Ollama tentato per PRIMO in ogni runWithFallback; se offline la chain scende su Groq !' Gemini !' OpenAI. | Engine Selector AI: 2 fasi — Fase 1 Ollama (½ budget 800ms), Fase 2 cloud chain (skipOllama:true). | Chat co-pilot moderazione: skipOllama:true, tool calling multi-step — cloud-only. | DB Watchdog (proposer): 3-step — (0) Ollama, (1) Groq specifico, (2) chain cloud; cooldown 30min. | Route AI: chain separata Ollama-first, configurabile via DB ai_route_provider_chain / env ROUTE_AI_PROVIDERS.

2. Feature AI — Dettaglio per Modulo

Feature	File / Modulo	Provider primario	Modello	Fallback	Note
Triage moderazione	server/ai/moderation/triage.ts	Ollama (first)	llama3.1:8b (Ollama) !' openai/gpt-oss-20b (Groq, brain) !' gemini-2.5-flash !' gpt-5.1	Rule-based se budget esaurito; cascade automatica se provider KO	Role: brain; generateObject; schema Zod; retry x2; log ai_call_logs
AI Assistant (chat utente)	server/ai/assistant/agent.ts	Ollama (first)	llama3.1:8b (Ollama) !' openai/gpt-oss-20b (Groq, router) !' gemini-2.5-flash-lite !' gpt-5.1	Cascade universale Ollama-first; ollamaBackstop ora ridondante (Task #3872)	Streaming SSE; RAG 3-snippet; memoria DB; tool call Ollama (maxSteps:3)
Route AI Parse (JSON)	server/routes/planned-routes/waypoints.ts +waypoints.next.ts server/ai/route-provider-config.ts	Ollama (primary)	llama3.1:8b (Ollama) !' Groq parse model !' gemini-2.0-flash !' gpt-4o-mini	Chain configurabile DB/ env; probe raggiungibilità Ollama; schema Zod + balanced-JSON	Timeout GEMINI_TIMEOUT_MS (30s); POI via Overpass; stats per provider
Route AI Stream (SSE)	server/routes/planned-routes/waypoints.ts +waypoints.next.ts server/ai/route-provider-config.ts	Ollama (primary)	llama3.1:8b (Ollama) !' Groq !' Gemini !' OpenAI	Buffering Ollama: emette solo se JSON valido; ricade su cloud se non valido	Evento SSE done con parsed; validazione tryParseRoute progressiva
Engine Selector AI	server/routing/ai-engine-decider.ts	Ollama (fase 1)	Fase 1: llama3.1:8b (Ollama, ½ budget) Fase 2: openai/gpt-oss-20b !' gemini-2.5-flash-lite !' gpt-5.1 (skipOllama:true)	Timeout 800ms totale; Fase 1=400ms Ollama; Fase 2=cloud residuo; scade !' rule-based	Sceglie GH vs Valhalla; input: bbox quality + health + ora; confidence<0.6 !' doppia route
DB Integrity Watchdog	server/ai/db-integrity/scheduler.ts +worker.ts server/ai/watchdog/proposer.ts	Ollama !' Groq	llama3.1:8b (Ollama, step 0) !' openai/gpt-oss-20b (Groq, step 1) !' chain cloud (step 2)	3-step manual: Ollama !' Groq specifico !' chain cloud (skipOllama:true); cooldown 30min	Scan notturno 03:00 + domenica 04:00 (expensive); cron croner; BullMQ

Embeddings (generazione)	server/embeddings/client.ts	OpenAI	text-embedding-3-large (dim=1536)	HF locale Xenova/ multilingual-e5-small (384!'1536, 4× concat + L2)	Timeout 15s; retry ×3; tag model in DB: openai: vs local:
Coordinate/geocode AI prompt	server/routes/planned-routes/ waypoints.ts	Non AI	Nominatim (OSM self- hosted)	Overpass per POI search	Downstream dall'AI Parse; no provider AI diretto

3. Meccanismi Trasversali

Ø=Ü° Budget Mensile • Limite default: \$55/mese • Alert push a 80% utilizzo • Freeze chat al 100%; triage !' rule-based • Scopes: chat, triage, digest, anomaly • Tabella: ai_usage_budget (per mese) • Costo via estimateCostUsd() (prezzi per modello)	Ø=Ý Circuit Breaker + Cooldown • Errore generico: 60s cooldown (in-memory) • Errore quota/rate limit: 6h (persistito DB) • Pattern: quota, rate_limit, RESOURCE_EXHAUSTED • Cap RPD: Groq 1.000, Gemini 1.500, OpenAI " • Groq TPD soft-cap: 160k token/giorno • Ripristino via initProviderHealth() al boot	#ñ Rate Limiter RPM (Bottleneck) • Ogni provider ha uno scheduler dedicato • Groq: 30 RPM (free tier) • Gemini: limiter RPM configurato • Ollama: pass-through (nessun limite) • OGNI chiamata AI DEVE passare da m.scheduler()
Ø<ß AiCoordinator — Event Bus • Singleton: getCoordinator() • emit !' ai_events + Redis pub/sub • subscribe !' Redis + fallback in-process • recordDecision !' ai_decisions • evaluateConflict !' ai_conflicts + policy • Admin bypass: aiName='admin' non bloccato	Ø=Ý4 Kill Switch / Pause • Pausa per-AI o globale (aiName="") • Stato Redis con TTL; fallback in-memory • pauseAi(), resumeAi(), listPaused() • Emit silenzioso se AI in pausa • COORDINATOR_DISABLED=1 disabilita tutto	Ø>Ýà Memoria Conversazionale + RAG • Tabella: ai_conversation_turns • Ultimi N turni per contesto (MEMORY_TURNS_LIMIT) • RAG: top-3 snippet da knowledge base • Pruning asincrono (fire-and-forget) • Tool calling: attivo solo su Ollama (maxSteps:3)
Ø=ÜÊ Logging AI Usage • Log: provider, model, tokensIn/Out, latencyMs • Log: costUsd, degraded, error • Tabella: ai_call_logs (assistant + triage) • Groq token tracking !' soft-cap TPD • Fire-and-forget (non bloccante)	Ø=Ý Watchdog AI Proposer • Routing 3-step: (0) Ollama, (1) Groq specifico, (2) chain cloud • Cooldown 30min se problema high/critical persistente • Scan: notturno 03:00, domenicale 04:00 (expensive) • Cleanup quarantena ogni 6h via croner • Anomalie via BullMQ worker	Ø=Ýú AI Routing Engine Selector • Attivo se maps_routing_engine = 'ai' • Sceglie: GraphHopper vs Valhalla • Fase 1: Ollama (½ budget 800ms); Fase 2: cloud (skindama 800ms !' ricade su rule-based) • Confidence < 0.6 !' doppia route + confronto

4. Stack Embeddings

Ø>Ý Provider primario — OpenAI • Modello: text-embedding-3-large • Dimensioni: 1536 (via providerOptions su dim nativa 3072) • Tag DB: openai:text-embedding-3-large • Timeout: 15s · Retry: x3 su 429 / 5xx • Attivo quando: OPENAI_API_KEY presente	Ø=Ý Fallback locale — HuggingFace Transformers • Modello: Xenova/multilingual-e5-small (quantized) • Dim nativa: 384 !' 1536 via 4x concat + L2-normalize • Tag DB: local:Xenova/multilingual-e5-small • Caricamento pigro (lazy): init solo alla prima chiamata • Attivo quando: OPENAI_API_KEY assente o quota esaurita
--	---

& þ Cross-provider similarity: La similarità coseno tra vettori OpenAI e vettori locali NON è significativa. Il matcher filtra per campo model quando serve confronto omogeneo. Le righe local: sono confrontabili solo tra loro.

5. Variabili d'Ambiente — Riepilogo

Variabile	Provider / Feature	Note
GROQ_API_KEY	Groq (primario)	Free tier — 30 RPM, 1.000 RPD, TPD soft-cap 160k token. Override: GROQ_RPD_LIMIT, GROQ_TPD_LIMIT
GEMINI_API_KEY / GOOGLE_API_KEY	Gemini (fallback)	Free tier Google AI Studio — 1.500 RPD. Override: GEMINI_RPD_LIMIT. Flash-lite su router, Flash su brain
OPENAI_API_KEY	OpenAI + Embeddings	Pay-per-use. Nessun cap RPD di default (Infinity). Attiva anche text-embedding-3-large
OLLAMA_URL	Ollama (self-hosted)	ThinkCentre LAN/Cloudflare. Se assente, Ollama disabilitato. Modello: OLLAMA_MODEL (default llama3.1:8b)
COORDINATOR_DISABLED	AiCoordinator	Se =1, tutto il layer coordinator è disabilitato (emit/subscribe no-op)
GEMINI_TIMEOUT_MS	Route AI Parse/Stream	Timeout globale AI route planning (default 30.000ms)
VALHALLA_URL	AI Engine Selector	Se assente, il selector AI sceglie sempre GraphHopper con confidence alta

' Livello di resilienza: il sistema funziona con un solo provider configurato. Con solo GROQ_API_KEY tutte le feature AI sono attive (eccetto embeddings OpenAI). Con zero chiavi cloud ma OLLAMA_URL configurato, l'AI assistant è operativo in modalità degradata. Con zero provider, il server parte comunque e il triage usa il fallback rule-based deterministico.

12 giugno 2026

12 giugno 2026

12 giugno 2026

